

TAL Statistique

Juan Manuel Torres-Moreno

juan-manuel.torres@univ-avignon.fr

LIA/Université d'Avignon

Dune (Denis Villeneuve), 2021



ALLOCINÉ

Rechercher un film, une série, une star...



Ex. : Avatar 2, Black Panther 2, Top Gun 2

CINÉMA

SÉRIES

STREAMING

NEWS

TRAILERS

DVD

VOD

KIDS

Meilleurs films

Films à l'affiche

Prochainement

Séances

Box Office

Courts-métrages

Tous les films



Maxime VANDAE...

Suivre son activité

Lire ses 2 critiques

★ ★ ★ ★ ★ 0,5 Publiée le 19 septembre 2021

Le point positif : c'est très beau.

Les points négatifs :

- La musique passe inaperçue (alors que Hans Zimmer quoi). Aucun thème marquant, peut-être un passage sympa avec les soeurs du bénévolat machin (les chuchotements).
- il y a que des acteurs bankable du moment au casting, et perso ça me sort total du film : "ah oué c'est cet acteur que j'ai déjà vu joué dans 5 film/séries sur les 3 dernières années!").
- Et surtout, surtout, ça manque cruellement de scènes mémorables et d'émotions : joie, tristesse, peur, colère, anxiété. Vous savez, ces choses qui sont censées être ce que l'on va chercher au cinéma. Bah il n'y en a pas. Ce film est clinique. Aussi sec que le désert dans lequel il prend place. Quand j'y réfléchi, Denis Villeneuve n'a jamais réussi à me filer une vraie émotion de toute sa carrière, et c'est peut-être là son point faible.

Bref, pour toutes ces raisons : non, ce film n'est pas un chef d'oeuvre.

Dune (Denis Villeneuve), 2021

[CINÉMA](#)[SÉRIES](#)[STREAMING](#)[NEWS](#)[TRAILERS](#)[DVD](#)[VOD](#)[KIDS](#)[Meilleurs films](#)[Films à l'affiche](#)[Prochainement](#)[Séances](#)[Box Office](#)[Courts-métrages](#)[Tous les films](#)

Léo Viguier

[Suivre son activité](#)

[Lire sa critique](#)

★☆☆☆☆ 0,5 Publiée le 19 septembre 2021

Certainement le pire film que j'ai vu au cinéma de toute ma vie. 2h30 de calvaire se résumant à des combats sans fins et des dialogues dont le contenu se rapproche d'un dessin animé entre les gentils qui veulent pas faire de mal au gens du sable et les méchants qui veulent tuer tout le monde et faire que du profit !

Je n'ai jamais rédigé de note mais je ne pouvais pas supporter de voir un tel navet noté +4/5...



[< PRÉCÉDENTE](#)

1

2

[SUIVANTE >](#)

Dune (Denis Villeneuve), 2021



★☆☆☆☆ 0,5 Publiée le 19 septembre 2021

Des décors et des costumes sans créativité. Une histoire qu'on a déjà vu mille fois. Aucune émotion, ce film m'a laissée totalement froide.



cat29

Suivre son activité

Lire ses 5 critiques



★☆☆☆☆ 0,5 Publiée le 19 septembre 2021

Quel ennui ! Ce n'est pas une question de lenteur c'est creux. Pas de dialogue, acteurs inexpressifs. Bande son feignante comme automatique et vraiment peu inspirée genre musique au mètre. Avec ce cri qui surgit régulièrement de façon grotesque Nyaaaaheheae ! J'ai faillit partir 1 bonne heure avant la fin je n'aurai pas manqué grand chose. Franchement à éviter. C'est un film sans énergie comme délavé, faussement humble comme son réalisateur. Qui tape sur le MCU et recycle des acteurs emblématiques de Marvel du coup ça dessert le tout le casting n'a aucun sens.

Gart

Suivre son activité

Lire sa critique

Dune (Denis Villeneuve), 2021

25 CRITIQUES DE 0 ET 0,5 ÉTOILE

Trier par

Critiques les plus utiles



Le Magic-mailla

Suivre son activité

Lire sa critique

★☆☆☆☆ 0,5 Publiée le 17 septembre 2021

Ce film est pourrie sur tout quand on sait qu'il ce permet d'attaquer le MCU (marvel cinématique univers) gros debile

😊 0 😞 3



Renaud1972

Suivre son activité

Lire sa critique

★☆☆☆☆ 0,5 Publiée le 18 septembre 2021

C'est lent, c'est mou, c'est d'un ennui indicible. On s'endort, on se fait chier. Un non sens. David Lynch was so dawn right!!!

😊 0 😞 0

70 CRITIQUES DE 3 ET 3,5 ÉTOILES

Trier par

Critiques les plus utiles



Falheim

Suivre son activité

3 abonnés

Lire ses 8 critiques

★★★★☆ 3,0 Publiée le 15 septembre 2021

N'y allons pas par quatre chemins : Non, Dune 2021 de Denis Villeneuve n'est pas LE film Dune que j'attendais en tant que fan de l'univers, celui que Jodorowski nous à fait rêver, le film qui saurait restituer toute la magie des livres, avec son ambiance mystique voir psychédélique par moments. Non, on se retrouve ici devant un film qui est certes réussi, joli, qui propose une certaine ambiance et de beaux effets spéciaux (mention spéciale aux Ornithoptères superbes) et qui suit dans les grandes lignes la trame principale de la première partie du roman, ce qui n'est pas une mince affaire, mais qui malgré sa longueur ne prend pas bien le temps de tout nous expliquer, surtout pour ceux n'ayant pas lu les bouquins, je n'imagine même pas l'enfer pour comprendre. Comme beaucoup de films de notre époque, tout s'enchaîne malheureusement un peu trop vite et on ne prend pas le temps de poser le décor, d'introduire le background (le Landsraad, l'Imperium...), les personnages, les enjeux... Au lieu de cela, on survole vite fait, on balance 2 ou 3 mots pour avoir placé les termes, mais ça s'arrête là. D'ailleurs c'est bien simple, je crois qu'à aucun moment il n'est fait mention, chose incroyable mais vrai, du Jihad Butlérien dans tout le film, ce qui est quand même la base de l'histoire de Dune ! Le fait que les hommes se soient libérés des machines

de Dune ! Le fait que les hommes se soient libérés des machines dans une révolte et que les machines pensantes soient désormais proscrites. On ne parle pas non plus de l'interdiction des atomiques et des armes à feus à cause de l'effet Holtzman sur les boucliers, raison pour laquelle les personnages combattent principalement à l'arme blanche. Le spectateur qui ne sait pas ça doit se demander pourquoi tout le monde combat principalement à l'épée. J'ai été très surpris de voir à quel point on ne précise pas non plus l'objectif du Bene Gesserit, spoiler:

, les Mentats (d'ailleurs ce terme n'est pas prononcé une seule fois non plus je crois bien) pour lesquels on explique à aucun moment qu'ils sont des assassins capable de facultés de raisonnement hors-pair, on ne voit que brièvement leurs yeux devenir tout blanc en se demandant s'ils ne font pas une crise d'épilepsie. C'est dommage, j'ai trouvé la narration assez confuse, après je peux comprendre qu'au vu de la complexité de l'univers et des nombreuses factions, Denis Villeneuve ait préféré se concentrer sur le principal. Bref pour moi c'est un film qui s'adresse surtout à ceux qui connaissent déjà l'univers et qui ont lu les livres, car sinon il me semble difficile

l'univers et qui ont lu les livres, car sinon il me semble difficile d'appréhender tout ce qui se dit dedans et les enjeux. Si Timothée Chalamet est physiquement très bien pour incarner le personnage de Paul Atréides, je trouve qu'il manque d'un petit quelque chose (au point presque de me faire regretter Kyle McLachlan qui avait je trouve, plus de prestance), de même que Jessica ou Leto qui incarnent mal leur rang de chefs des Atréides. Lyet la planétologue, qui devient une femme au passage, ne détail pas son rôle ni l'importance de la végétation sur Arrakis, c'est vraiment extrêmement survolé. Je trouve aussi maladroites certaines mises en scènes, comme l'utilisation de la "Voix" qui m'a vraiment fait craindre le pire au tout début du film et qui peut avoir l'air ridicule par moments, et enfin, je ne suis vraiment mais alors vraiment pas fan du rendu des Vers de sable, qui sont certes impressionnants quand ils arrivent du sable, mais qui ne ressemblent vraiment à rien avec leurs cure-dents en trop gros surnombre. Pour le coup, le Dune de David Lynch tant décrié était clairement bien mieux en terme d'esthétique pour ses Vers de sable. Enfin, on échappe pas à quelques répliques un peu trop "films modernes/humour vulgaire" qui cassent un peu le coté sérieux de Dune et qui nous sortent un peu de l'oeuvre originale spoiler:

de l'oeuvre originale spoiler:

heureusement peu nombreux. Passez tous ces petits coups de gueule (oui je critique beaucoup), on reste sur un film tout de même bien maîtrisé, avec de beaux décors, qui sait parfois mettre l'action de côté pour nous immerger dans l'ambiance, chose rare de nos jours, mais qui malheureusement ne parle pas toujours des choses importantes pour le spectateur. Il manque quelques éléments scénaristiques comme Feyd Rutha, la CHOM et je le redis, l'objectif des Bene Gesserit et des détails sur La Grande Révolte et le Jihad Butlérien qui sont quand même pour moi au coeur de l'histoire (un simple texte en introduction ou une voix narrative de 2min auraient suffi). Ils auraient du avoir recours à une voix narrative aussi pour connaître la pensée des personnages par moments, plutôt que de tout vouloir montrer visuellement. La restitution de l'oeuvre est donc partiellement là, le principal, mais il manque quelque chose qui fait que je ne suis pas ressorti de la salle pleinement satisfait, même si content tout de même. Bon film mais qui aurait pu être mieux expliqué, mieux détaillé, sans pour autant rallonger la durée, mais ça reste tout de même une prouesse d'avoir réussi à faire quelque chose de bon au vu de la complexité de la tâche. Un petit bravo à Villeneuve malgré tout, mais pas le "Messie" tant attendu. Je suis curieux de voir la suite, car ce n'est que la première partie !

Dune (Denis Villeneuve), 2021

305 CRITIQUES DE 5 ETOILES

Trier par

Critiques les plus utiles



AngelCoinCoin

Suivre son activité

24 abonnés

Lire ses 12 critiques

★★★★★ 5,0 Publiée le 15 septembre 2021

Je fais partie des gens qui vénèrent la lenteur narrative. J'aime qu'on prenne le temps de mettre en place la narration, les personnages, l'ambiance, la mythologie. A ceux qui démontent le film sur la lenteur, je dirais simplement que le roman est long, très long, et qu'il prend également le temps de poser sérieusement le contexte.

Si on y ajoute une photographie impeccable, une bande son de qualité, des acteurs et actrices au plus près de leur rôle, un montage précis et intelligent, on est proche du chef d'œuvre à mes yeux. Je ne suis fan ni de Villeneuve ni de Chalamet, mais au final, ayant lu les romans, adoré le film de Lynch, et joué aux différents opus des jeux pendant des heures et des heures, j'avoue, je suis conquise, et je vais tout péter si on n'a pas la suite!

Je met rarement 5 étoiles et je vois énormément de films. Ici, c'était une évidence.



nicolas antonini

[Suivre son activité](#)

4 abonnés

[Lire sa critique](#)

★★★★★ 5,0 Publiée le 7 septembre 2021

Vu en avant première, parfaite interprétation du livre, on comprend tous les enjeux géo politique de cet univers, super acteurs, jolie photo, bande son extraordinaire, espérons que les ricains aient le voir en salle et non en streaming qu'on est la suite, chef d'œuvre

😊 20 😞 5



Anthony B.

[Suivre son activité](#)

9 abonnés

[Lire sa critique](#)

★★★★★ 5,0 Publiée le 14 septembre 2021

Alors pour faire simple la 1ere claqué que vous allez vous prendre c'est Hans Zimmer et sa musique !

Elle fait partie intégrante de chaque scène du film, et participe à l'immersion !

Ensuite les effets spéciaux, la mise en scène, le rythme c'est pfiou !! "bordel ça fait déjà 1h de film !?" "Mais non pas possible !" "Ah bah si en fait, on aurait pensé 30 :o"

Il se passe toujours quelque chose, chaque dialogue est placé là où il doit être et à une raison d'exister, pas de remplissage bête juste pour faire beau, en clair une maîtrise parfaite du montage et de la mise en

Dune (site Téléràma)

Satisfaction communauté

T 81%

Dune (2021) un film de Denis Villeneuve



Ce qu'en pense la communauté

152 membres le recommandent



? Demander l'avis de mes amis...

187
notes

124
veulent
le voir


plus de
stats

Micro-critique star (**Thumb**) :

Sa note : ★★★★★

“ Sous la chaleur de Dune émanent les prémices d’une épopée saisissante, où se côtoient conflits géopolitiques et quête de soi. Monumental ! ”

il y a 5 jours

Dune (Denis Villeneuve), 2021



PharaonDeWinter
(à propos de [Dune](#))

Sa note : ★★☆☆☆

“ La platitude de la version de V n'aura qu'un intérêt : l'actualisation de la norme du kitsch, adapté à l'époque, via le design et le chrome. ”

hier à 12:51



sergito
(à propos de [Dune](#))

Sa note : ★★☆☆☆

“ Recréation de la SF assez réussie. Mais l'action s'enlise dans le désert dès la fuite de Paul et sa mère. Lourd, didactique, interminable. ”



MadHeath
(à propos de [Dune](#))

Sa note : ★★☆☆☆

“ D.Villeneuve s'emmêle les pinceaux entre expositions et accélérations. Il accouche d'un monde foisonnant d'ambitions mais qui manque de vie. ”

il y a 5 jours



J-L.L Le vers à moitié vide...

il y a 4 jours

Dune (Denis Villeneuve), 2021



NelRitour

(à propos de [Dune](#))

Sa note : ★★☆☆☆

“ Entre deux images de synthèse façon Disney et des chorégraphies martiales illisibles, Dune trace son chemin sans enjeu, pour le spectacle. ”

il y a 4 jours



lekid

(à propos de [Dune](#))

Sa note : ★★★★★

“ "Dans les dunes, quelque chose rayonne en silence." dit le Petit Prince découvrant Arakis. Tout vibre devant Dune, les yeux et l'esprit. ”

il y a 5 jours



lekid Très librement inspiré d'Antoine de Saint-Exupéry

il y a 5 jours



jroux86 "S'il vous plaît monsieur, dessine moi... un bon gros ver géant !"

il y a 4 jours



lekid @jroux86 ça fait beaucoup moins rêver !!!

il y a 4 jours

Comment traiter automatiquement ce genre de textes?

- Commentaires
- Micro-commentaires
- Commentaires sur les commentaires...
 - Positifs, négatifs, neutres, autres?

*Essayons de voir un peu plus clair avec des
outils TAL: points forts et faibles*

Que faire avec du TAL statistique?

- Recherche à résoudre le problème d'acquisition:
 - En apprenant automatiquement des caractéristiques des données (lexiques ou syntaxiques)
- Solution au problème de l'ambiguïté des données car les modèles statistiques
 - sont robustes
 - généralisent bien
 - se portent bien en présence de :
 - erreurs
 - bruit
 - nouvelles données

Pour quoi étudier TAL statistique?

- **Les méthodes statistiques** sont
 - Flexibles
 - Robustes
 - Reposent sur la **Théorie des probabilités**:
approximation de la réalité

Corpus = Données (textuelles, parole)

- **Corpus d'apprentissage**

- Approcher la distribution de probabilités d'une langue

Corpus de test

Indépendant de l'apprentissage: évaluation

- **TAL statistique :**

- Automatiser le processus pour apprendre des particularités lexicales et structurales à partir des corpus

Corpus

- Grandes bases de texte (et parole)
- Types de corpus
 - Texte brut, domaine spécialisé, annoté, parsé, bilingue, ...
- Sources:
 - Linguistic data Consortium (LDC) -- www ldc.upenn.edu
 - European Language resources Associations (ELRA) -- www.icp.grnet.fr/ELRA
 - ..
- Un corpus doit être:
 - Suffisamment grand
 - Échantillon représentatif de la population de intérêt

Format de bas niveau

- Format et contenu

- Eliminer tags (HTML, XML), diagrammes, tables, mots en langue étrangère, etc.
- Problème : corpus OCR / PDF

- Majuscules / minuscules

- Garder la case?
- “*la*”, “*La*” et “*LA*” doivent être également traités?
- “*George Brown*” , “*brown dog*”, “brown” : traités différemment... ?

Tokens et phrases

- Tokenisation
 - découper le texte en unités (*tokens*)
 - token peut-être un mot ou autre chose... (chiffres, ponctuation,...)
- Frontières de phrases
 - Plusieurs phrases se terminent avec . ? !
 - ...Problème : les abréviations

Example

- Corpus :

Bogota, 9 jan 90 (EFE) -- [text] Ricardo Alfonso Castellar, mayor of Achi, in the northern department of Bolivar, who was kidnapped on 5 January, apparently by army of national liberation (ELN) guerrillas, was found dead today, according to authorities.

Castellar was kidnapped on 5 january on the outskirts of Achi, about 850 km north of Bogota, by a group of armed men, who forced him to accompany them to an undisclosed location.

Police sources in Cartagena reported that Castellar's body showed signs of torture and several bullet wounds.

Castellar was attacked by ELN guerrillas while he was traveling in a boat down the Cauca river to the tenche area, a region within his jurisdiction.

In Cartagena it was reported that Castellar faced a “revolutionary trial” by the ELN and that he was found guilty and executed.

Entités nommées

Noms de personnes

Noms de lieux

- Villes
- Pays
- ...

Noms d'organisations

- Entreprises
- Gouvernements
- ...

Dates

Quantités

Exemple

- Tags entités **nommées** :

<ENAMEX TYPE= LOCATION> Bogota </ENAMEX>, <TIMEX TYPE= DATE> 9 jan 90 </TIMEX> (<ENAMEX TYPE= ORGANIZATION> EFE </ENAMEX>) -- [text] <ENAMEX TYPE= PERSON> Ricardo Alfonso Castellar </ENAMEX>, mayor of <ENAMEX TYPE= LOCATION> Achi </ENAMEX>, in the northern department of <ENAMEX TYPE= LOCATION> Bolivar </ENAMEX>, who was kidnapped on <TIMEX TYPE= DATE>5 January</TIMEX>, apparently by <ENAMEX TYPE= ORGANIZATION> army of national liberation (ELN) </ENAMEX> guerrillas, was found dead today, according to authorities.

<ENAMEX TYPE= PERSON> Castellar </ENAMEX> was kidnapped on <TIMEX TYPE= DATE> 5 january </TIMEX> on the outskirts of <ENAMEX TYPE= LOCATION> Achi </ENAMEX>, about 850 km north of <ENAMEX TYPE= LOCATION> Bogota </ENAMEX>, by a group of armed men, who forced him to accompany them to an undisclosed location.

...

Que faire avec les corpus?

Compter :

- Mots fréquents
- Tokens
- Mots type (uniques)
- Fréquence des mots

Compter les mots

Un mot quelconque dans un **corpus** est appelé une **occurrence** (ou une **instance**, ou très souvent encore un **token**). C'est la réalisation d'un **type** particulier.

Soit le corpus suivant:

Ca c' est pour moi , le plus beau et le plus triste paysage du monde . C' est le même paysage que celui de la page précédente , mais je l' ai dessiné une fois encore pour bien vous le montrer .

Il y a 43 occurrences dans ce corpus (en comptant les signes de ponctuation), mais il y a seulement 34 types (en distinguant majuscule/minuscule; 33 sinon). 75% de ces types ont une **fréquence** de 1 dans ce corpus.

Qu'est-ce qu'une phrase ?

- Se terminent en . ? !
 - 90% des cas
- Delimitées par d'autres symboles
 - Ex: phrases imbriquées:
 - “You remind me,” she remarked, “of your mother.”
- Heuristiques
 - Règles codées à la main
- Méthodes statistiques pour détection des frontières de phrases
 - Problème typique de classification
 - Classifier le . comme un marqueur de fin de phrase ou non
 - Caractéristiques comme majuscules/minuscules, longueur, étiquette du mot précédant le point...
 - Utilisation d'arbres de décision, réseaux de neurones...

Taux de bon classification : **98-99%**

Qu'est-ce qu'une phrase ?

On disait dans le livre : « les serpents boas avalent leur proie tout entière, sans la mâcher. Ensuite ils peuvent plus bouger et ils dorment les six mois de leur digestion »

Qu'est-ce qu'une phrase ?

Exemple extrait de [Véronis and Langlais, 2000] p. 372:

⟨S⟩ On disait dans le livre: “Les serpents boas avalent leur proie tout entière, sans la mâcher. Ensuite ils ne peuvent plus bouger et ils dorment pendant les six mois de leur digestion” ⟨/S⟩

⟨S⟩ On disait dans le livre: ⟨/S⟩⟨S⟩ “Les serpents boas avalent leur proie tout entière, sans la mâcher. Ensuite ils ne peuvent plus bouger et ils dorment pendant les six mois de leur digestion” ⟨/S⟩

⟨S⟩ On disait dans le livre: ⟨/S⟩ “⟨S⟩ Les serpents boas avalent leur proie tout entière, sans la mâcher. ⟨/S⟩ ⟨S⟩ Ensuite ils ne peuvent plus bouger et ils dorment pendant les six mois de leur digestion ⟨/S⟩

⟨S⟩ On disait dans le livre: “ ⟨S⟩ Les serpents boas avalent leur proie tout entière, sans la mâcher. Ensuite ils ne peuvent plus bouger et ils dorment pendant les six mois de leur digestion ⟨/S⟩” ⟨/S⟩

Tokens – Qu'est-ce qu'un mot?

- Mot graphique (Kučera and Francis, 1967):
 - “A string of contiguous alphanumeric characters with white spaces on either side; may include hyphens and apostrophes, but no other punctuation marks”
 - Mais ... \$22.50 C++ :-) ; -)
- Problèmes:
 - Points
 - Abréviation ou fin de phrase ?
 - “*etc.*” “*Calif.*” “*Wash.*”
 - Point fait partie du mot ?
 - “*Wash.*” (Washington) doit garder le point pour le distinguer de “*wash*” (verbe)
 - Apostrophes
 - Partie d'un mot ?
 - “*John's sick*” | m'a dit -> 1, 2 ou 3 mots ?
 - Si 1 mot, entonces 's est un verbe ?
 - Si 2 mots, alors “*John's house*” doit être traité comme 3 mots?

Problèmes: tokenisation

- Identifier mots et frontières de phrases et le problème de la ponctuation ambiguë
- Problème majeur: le point
 - Brown corpus:
 - 52511 phrases se terminent par un point finale .
 - 3569 contiennent un point . non finale
 - 93.2 % exactitude si le . est interprété comme fin de phrase... mais 7 % d'erreur !

Tokens – Qu'est-ce qu'un mot?

- **Coupures** : Que représente le tiret ?
 - “*e-mail*” “*pro-life*” “*data-base*” “*database*” “*data base*”
- **Accents**
 - Les effacer ?
- **Homographes (homophones)**
 - Distinction entre mots avec la même graphie mais différente signification
 - “*pas*”: negation / marcher
 - “*Saw*”: instrument / passé de “*to see*”
- **Segmentation de mots dans d'autres langues:**
 - Il ya des langues ou il n'ya pas des espaces en blanc !!!
 - Ex: langues est-Asie
 - En allemand : “Employé d'une compagnie d'assurance” :
“*Lebenversicherungsgesellschaftsangestellter*”

Tokens – Qu'est-ce qu'un mot?

- **Variantes de types sémantiques**
 - Ex. Téléphone
 - (514) 848-3074
 - +1 514 848 3074
 - +1 (514) 848 3074
 - 33 (0) 4.90.84.35.68
 - 04.90.84.35.68
- **Le blanc n'est pas toujours un séparateur des mots :**
 - “*in spite of*” (*malgré que*)
 - “*as a matter of fact*” (*en fait*)
 - “*work out*” (*réaliser*)

Problèmes : abréviations et lexique

- Heuristique: point (.) suivi de non-blanc n'est pas une fin de phrase :
 - Précision : 93.8 % (encore **6 % d'erreur**)
- Abréviations
 - A.,B., U.S., k.p.h.
 - Mr., St.
 - Précision : 97.7 % (< **3 % d'erreur**)
- Autres problèmes
 - Mix : 12h30 vs. 12:30 pm
 - Bruit : km/h vs. k.m/h.
 - Précision : > 98 % (< **2 % d'erreur**)

Tokens -- Variations

- Variations morphologiques?
 - Doivent : “give”, “gives”, “given”, “giver”... être considérés comme des mots différents?
- Objectif : “normaliser” les mots similaires
- Deux approches :
 - Stemming
 - Lemmatisation (Analyse morphologique)

Encore des mots

I have a can opener; but I can't open these cans.

- Combien de mots ?
- Forme des mots
 - Forme fléchit comme dans le texte
 - *can* et *cans* ... formes différentes
- Lemma
 - ensemble de formes lexiques possédant la même racine, même étiquette grammaticale (Verbe, adjectif, etc) et même signification
 - *can* et *cans* ... pas le même lemme !
- Mot brut (token):
 - Occurrence de mots
 - *I have a can opener but I can (no)t open these cans* **12 tokens** (sans ponctuation)
- Mots types (uniques):
 - *I have a can opener but I can (no)t open these cans* **10 mots différents** (sans ponctuation)

Exemples

- *Tom Sawyer* de Mark Twain
71,370 mots
8,018 mots types (uniques)
 $\rho = \text{mots/types} = 8.9$ (complexité du texte)
- Oeuvres complètes de Shakespeare
884,647 mots
29,066 mots types
 $\rho = 30.4$ bien plus complexe !

Mots courants dans *Tom Sawyer*

Word	Freq.	Use
the	3332	determiner (article)
and	2972	conjunction
a	1775	determiner
to	1725	preposition, verbal infinitive marker
of	1440	preposition
was	1161	auxiliary verb
it	1027	(personal/expletive) pronoun
in	906	preposition
that	877	complementizer, demonstrative
he	877	(personal) pronoun
I	783	(personal) pronoun
his	772	(possessive) pronoun
you	686	(personal) pronoun
Tom	679	proper noun
with	642	preposition

Les mots ont une distribution inégale ...

Fréquence de fréquences

Word Frequency	Frequency of Frequency
-------------------	---------------------------

1	3993
---	------

2	1292
---	------

3	664
---	-----

4	410
---	-----

5	243
---	-----

6	199
---	-----

7	172
---	-----

8	131
---	-----

9	82
---	----

10	91
----	----

11-50	540
-------	-----

51-100	99
--------	----

> 100	102
-------	-----

- La plupart des mots sont rares
 - 3993 (50%) types apparaissent seulement une fois **happax legomena** (*lus une seule fois*)
- Les mots courants sont **très courants**
 - 100 mots font > 50% de tous les tokens (de n'importe quel texte)

Compter les mots est intéressant !

- Indication du style
- Indication de l'auteur
- Mais, puisque les mots apparaissent comme un phénomène rare,
 - Il est difficile de prédire leur comportement
- Loi de Zipf

Loi de Zipf

1. Compter la fréquence des mots types dans un grand corpus
2. Trier les types en fonction de leur fréquence
 - Soit:
 - f = fréquence de un type
 - r = rang dans la liste

Loi de Zipf : $f \propto 1/r$

Loi de Zipf

- Dans d'autres mots :
 - Il y a une constante **k** telle que :
 $k = f \times r$
 - Le 50^{ième} type doit avoir une fréquence 3 fois la fréquence du type 150^{ième}

Loi de Zipf - Tom Sawyer


Mot	fréquence	rang	k
The	3332	1	3332
and	2972	2	5944
a	1775	3	5235
He	877	10	8770
but	410	20	8400
Be	294	30	8820
there	222	40	8880
one	172	50	8600
about	158	60	9480
more	138	70	9660
never	124	80	9920

Mot	fréquence	rang	k
you	130	500	9000
name	21	400	8400
comes	16	500	8000
group	13	600	7800
lead	11	700	7700
friends	10	800	8000
begin	9	900	8100
family	8	1000	8000
brushed	4	2000	8000
sins	2	3000	6000
Could	2	4000	8000
Applausive	1	8000	8000

- $k \approx 8000-9000$
- À exception de
 - 3 mots plus fréquents
 - mots de fréquence ≈ 100

Loi de Zipf

Tom Sawyer $k = f \times r$



Loi de Zipf

- Peu de mots très fréquents
- Nb moyen de mots ayant fréquence moyenne
- Grand Nb de mots peu fréquents
- Principe de l'effort minimale: différence entre le locuteur et l'effort de l'auditeur
- Le locuteur communique avec un petit vocabulaire de mots fréquents (moindre effort)

Que faire avec les corpus?

Trouver les collocations

- **Collocation**: un segment où on perçoit une expression dont son existence est plus grande que la somme de ses parts

ENGLISH

- *disk drive*
- *make up*
- *bacon and eggs*

FRANCAIS

- *Président de la république*
- *Président et Directeur Général*

ESPAÑOL

- *Grupo de Ingenieria Linguistica*
- *Estudiante de Informatica,*
- *Base de datos,...*

Collocations

- Importantes pour traduction automatique
 - *strong tea* → *thé fort*
 - *strong argument* → *argument fort ? convainquant*
- Peuvent être extraites du texte
 - Calculant les bigrammes plus fréquents
 - Plusieurs de ces bigrammes son souvent insignifiants (“at the”, “of a”, «et alors», ...)
 - Filtrage

Collocations

Bigrammes

Frequency	Word 1	Word 2
80871	of	the
58841	in	the
26430	to	the
21842	on	the
21839	for	the
18568	and	the
16121	that	the
15630	at	the
15494	to	be
13899	in	a
13689	of	a
13361	by	the
13183	with	the
12622	from	the
11428	New	York
10007	he	said
9775	as	a
9231	is	a
8753	has	been
8573	for	a

Bigrammes filtrés

Frequency	Word 1	Word 2
11487	New	York
7261	United	States
5412	Los	Angeles
3301	last	year
3191	Saudi	Arabia
2699	last	week
2514	vice	president
2378	Persian	Gulf
2161	San	Francisco
2106	President	Bush
2001	Middle	East
1942	Saddam	Hussein
1867	Soviet	Union
1850	White	House
1633	United	Nations
1337	York	City
1328	oil	prices
1210	next	year
1074	chief	executive
1073	real	estate

Que faire avec les corpus?

Concordances

- Trouver les différents contextes dans lesquels un mot occurre
- Logiciel Key Word In Context (KWIC)

1	could find a target. The librarian	"showed	off" - running hither and thither w
2	elights in. The young lady teachers	"showed	off" - bending sweetly over pupils
3	ingly. The young gentlemen teachers	"showed	off" with small scoldings and other
4	seeming vexation). The little girls	"showed	off" in various ways, and the littl
5	n various ways, and the little boys	"showed	off" with such diligence that the a
6	t genuwyne?" Tom lifted his lip and	showed	the vacancy. "Well, all right," sai
7	is little finger for a pen. Then he	showed	Huckleberry how to make an H and an
8	ow's face was haggard, and his eyes	showed	the fear that was upon him. When he
9	not overlook the fact that Tom even	showed	a marked aversion to these inquests
10	own. Two or three glimmering lights	showed	where it lay, peacefully sleeping,
11	ird flash turned night into day and	showed	every little grass-blade, separate
12	that grew about their feet. And it	showed	three white, startled faces, too. A
13	he first thing his aunt said to him	showed	him that he had brought his sorrows
14	p from her lethargy of distress and	showed	good interest in the proceedings. S
15	ent a new burst of grief from Becky	showed	Tom that the thing in his mind had
16	shudder quiver all through him. He	showed	Huck the fragment of candle-wick pe