

Université d'Avignon

Master 1 AMS1 – Génération automatique de graphes de personnages

Juan-Manuel Torres - Septembre 2026

Travaillez en binômes. Langages acceptés : **C/C++ ; python ; awk, rust, perl ; ruby ; bash.** Langages exclus : **R, java, javascript**

TP Entités Nommées: 23/09

Introduction

Un réseau de personnages est une visualisation permettant d'avoir une image globale des personnages d'un récit et leurs interactions. Plus formellement :

« Un réseau est un objet mathématique constitué d'un ensemble de nœuds, appelés aussi sommets – ici, les personnages – et d'un ensemble de relations définies sur des couples de nœuds. Les réseaux sont aujourd'hui des objets courants dans nombre de disciplines scientifiques ... de même qu'au sein d'infographies mises à disposition du grand public dans le champ du journalisme de données »¹

Nous voulons construire un graphe des personnages d'un texte narratif. En particulier nous voulons extraire les noms des personnages des romans de science fiction d'Isaac Asimov concernant le cycle de la Fondation. A savoir :

- Fondation
- Fondation et empire
- Seconde Fondation

Nous avons besoin des noms des personnages et des lieux où ils agissent. La tâche d'extraction des occurrences de ces noms dans le texte se nomme « détection d'entités nommées » (ou *named entity recognition* en anglais) [6].

Ce TP se décompose en 3 tâches :

- **Tâche 1/** Produire une liste d'entités nommées candidates en vrac et sans filtrage (liste **L**)
- **Tâche 2/** A partir de **L**, produire par raffinements (**filtrage, regexp, etc**) une liste d'entités nommées de personnes, liste **LP**
- **Tâche 3/** A partir de **L et LP**, produire une liste **LL** d'entités nommées de lieux (cités, organisations, universités, villes, planètes)

Pour bien mener ce TP, vous devez être en mesure de manipuler des ressources linguistiques (corpus textuels) ainsi que leurs représentations (n-grammes) et également de concevoir et de développer des algorithmes pour produire ces listes.

¹ <https://journals.openedition.org/resf/1183#tocto2n14>

- Un modèle de langue (ML) permet de capturer des régularités d'une langue à partir de corpus. Typiquement, il s'agit de tables contenant des fragments ou morceaux de texte et leur occurrence. Les morceaux de texte sont des n-grammes (séquences de $n=1,2,\dots$ tokens) où les n-grammes ont montré une grande utilité dans les tâches de Traitement Automatique des Langues.
- Les ML pourront servir pour construire des tables de co-occurrences de n-grammes.
- Les n-grammes ($n=1,2,3$) aident à produire des listes d'entités nommées potentielles, mais qui peuvent contenir du bruit. Il convient d'établir des heuristiques pour filtrer ces listes

Ressources linguistiques

Vous pouvez utiliser pour annoter les corpus:

- **POS freeling** : <https://freeling-user-manual.readthedocs.io/en/latest/tagsets/tagset-fr>
- **NLTK** : <https://www.nltk.org/book/ch05.html>
- **ANTIDICTIONNAIRE** français sur le site ENT

Les ressources que vous allez produire doivent être créées en texte codé utf8 afin qu'elles soient exploitables par les programmes à venir.



Attention ! Le corpus ASIMOV vous est fourni uniquement dans le cadre de ce cours. Vous ne devez en aucun cas le distribuer ailleurs. Vous vous engagez à l'effacer de votre ordinateur à la fin du cours.

Le corpus est un échantillon composé uniquement des pages IMPARES... attention donc aux paragraphes et mots coupés et incomplets...

Faut-il filtrer le corpus de la ponctuation ou d'autres symboles ? Réfléchissez aux impacts que cela peut avoir pour la suite du projet.

Soyez créatifs !

Rendu

Vous avez 2 séances TP pour réussir aux tâches.

Il faut un rendu simple :

- Petit rapport de 2-3 pages concernant vos algorithmes
- Vos résultats (Listes **L**, **LP**, **LL**) et statistiques du corpus

REFERENCES BIBLIOGRAPHIQUES

1. Moreno-Jiménez, L.G., Torres-Moreno, J.M., Wedemann, R.S., SanJuan, Eric : Generación automática de frases literarias. LINGUAMATICA (2020)
2. Moreno-Jiménez, L.G., Torres-Moreno, J.M., Wedemann, R.S.: Literary Natural Language Generation with Psychological Traits. NLDB 2020, Saarbrücken, Germany, (2020)
3. Moreno-Jiménez, L.G., Torres-Moreno, J.M., : MegaLite-2: An Extended Bilingual Comparative Literary Corpus. SAI 2020, London, UK, (2021)
4. Moreno-Jiménez, L.G., Torres-Moreno, J.M., Génération automatique de phrases littéraires : une approche combinant TAL et apprentissage automatique, pp 106-118, Spheres 2020
5. Filippova, K. Multi-Sentence Compression: Finding Shortest Paths in Word Graphs, pp 322-330 COLING 2010
6. Nadeau, D. and Sekine, S. : A Survey of Named Entity Recognition and Classification. Lingvisticae Investigationes, Vol. 30, Issue 1, pp 3-26. <https://nlp.cs.nyu.edu/sekine/papers/li07.pdf>